

Detekčný transformer a fundamentálne modely


25.2.2026, 15:00-17:00

Andrej Lúčny

Krížna pozornosť. Detekčný transformer (DeTR).
Vizuálny model s textovým promptom.
Fundamentálne modely: DINO, CLIP, Glee, SAM.


<https://github.com/andy1ucny/OAI>

Transformer




- postupne transformuje N skrytých stavov, kde N je veľkosť vstupu

Latentné priestory transformerov



- majú všetky určitú zvolenú dimenziu, ktorá určuje počet spôsobov, akými sa dva významy môžu líšiť
- významy sú reprezentované vektormi tejto dimenzie, pričom ich podobnosť je daná kosínusovou podobnosťou
- vektory (skryté stavy) obsahujú aj informáciu o pozícii vo vstupe

Kosínusová podobnosť



$$\text{sim}(\vec{u}, \vec{v}) = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\| \|\vec{v}\|} \quad <-1, 1>$$



$$\cos \phi = 1$$



$$\cos \phi = 0$$




$$\cos \phi = -1$$

keďže v transformere sú vektory podobnej veľkosti:

$$\text{sim}(\vec{u}, \vec{v}) \approx \vec{u} \cdot \vec{v} \quad <-\infty, \infty>$$

- nastoliť kosínusovú podobnosť medzi dátami pomáhajú normalizácie v rámci vrstvy, ktoré sú vložené medzi každé dva stavebné prvky

Normalizácia v rámci vrstvy (Layer Normalization)



$$LN(h) = w \frac{h - \mu_L}{\sqrt{\sigma_L^2 + \epsilon}} + b$$


Pozornosť (Attention)

*„snaž sa namiešať
dotaz z kľúčov a
vypočítaj analogickú
miešatinu hodnôt“*

k – počet
dotazov
(skrytých
stavov)

l – počet
párov kľúč-
hodnota

d – dimenzia,
počet príznačov




počet
kľúčov a
hodnôt
musí byť
rovnaký

$$O = \text{softmax} \left(\frac{QK^T}{\sqrt{d}} \right) V$$

$$\begin{array}{lll} Q: k \times d & K^T: d \times l & V: l \times d \\ K: l \times d & QK^T: k \times l & O: k \times d \end{array}$$

Autopozornost' (Self-Attention)



*Slovo **ball** má rôzny význam v rôznom kontexte*

He shot the ball into the net.
(the soccer ball)

The ball tore off his leg.
(the cannonball)

Slovo ball má rôzny význam v rôznom kontexte

He shot the ball into the net.
(the soccer ball)

The ball tore off his leg.
(the cannonball)

$\text{ball} = c_1 \text{ ball} + c_2 \text{ shot} + c_3 \text{ net}$

$\text{ball} = d_1 \text{ ball} + d_2 \text{ tore} + d_3 \text{ leg}$

Pre každé slovo vypočítame kosínusovú podobnosť s ostatnými (vrátane jeho)

ball ← query
dotaz

-1.2 14.3 -15.0 23.0 -6.4 -15.0 19.7

He shot the ball into the net

← keys
← klúče


ball ← query
dotaz

-15.0 23.0 19.2 7.2 -4.7 10.8

The ball tore off his leg



← keys
← klúče

Pre každé slovo vypočítame kosínusovú podobnosť s ostatnými (vrátane jeho) a aplikujeme Softmax



$$\text{softmax}_i(x_1, x_2, \dots, x_n) = \frac{e^{x_i}}{\sum_k e^{x_k}}$$

a potom miešaninou reprezentácie hodnôt nahradíme pôvodnú reprezentáciu; tým získa špecifický význam



Reziduálna autopozornosť (Residual Self-Attention)

$$\text{ball} = c_1 \text{ ball} + c_2 \text{ shot} + c_3 \text{ net}$$

$$c_1 = \text{sim}(\text{ball}, \text{ball})$$

$$c_2 = \text{sim}(\text{ball}, \text{shot})$$

$$c_3 = \text{sim}(\text{ball}, \text{net})$$




$$\text{ball} += f_o(c_1 f_v(\text{ball}) + c_2 f_v(\text{shot}) + c_3 f_v(\text{net}))$$

$$c_1 = \text{sim}(f_q(\text{ball}), f_k(\text{ball}))$$

$$c_2 = \text{sim}(f_q(\text{ball}), f_k(\text{shot}))$$

$$c_3 = \text{sim}(f_q(\text{ball}), f_k(\text{net}))$$

Reziduálna autopozornosť (Residual Self-Attention)



počet dotazov, kľúčov i hodnôt je rovnaký

Reziduálna krížna pozornosť (Residual Cross-Attention)

$$\text{ball} += f_o(c_1 f_v(\text{do}) + c_2 f_v(\text{you}) + c_3 f_v(\text{like}) + c_4 f_v(\text{soccer}))$$


$$c_1 = \text{sim}(f_q(\text{ball}), f_k(\text{do}))$$

$$c_2 = \text{sim}(f_q(\text{ball}), f_k(\text{you}))$$

$$c_3 = \text{sim}(f_q(\text{ball}), f_k(\text{like}))$$

$$c_4 = \text{sim}(f_q(\text{ball}), f_k(\text{soccer}))$$

Reziduálna krížna pozornosť (Residual Cross-Attention)




počet dotazov je iný ako počet kľúčov a hodnôt


<pad> Where does Beatles live ? <eos>

0 2840 405 27615 619 58 1

PE EMBEDDING





Decoder




Chatbot (transformer type encoder-decoder)

T4, Flan, LaMini







Chatbot (transformer type decoder-only)




<User:> What is
the capital of
the USA ?
<Assistant:>




<User:> What is
the capital of
the USA ?
<Assistant:> The



<User:> What is
the capital of
the USA ?
<Assistant:> The
capital




<User:> What is the
capital of the USA ?
<Assistant:> The capital
of the USA is
Washington , D . C .




Klasifikátor (transformer typu encoder-only)

BERT, RoBERTa




Klasifikačný skrytý stav je jediný vektor s dimenziou latentného priestoru

<pad> What is
the capital of
the USA ? <eos>




<a question on the capital cities>
<other question>

ViT



CLS

embedding



positional
encoding

layer normalisation

residual self-attention

heads

pozornostná
mapa

layer normalisation


FFN

layer normalisation

wipeout

reziduálne
spojenia

Nx



Detekčný transformer (DeTR)

- Transformer typu encoder – decoder
- Encoder zakóduje obraz (ViT bez CLS)
- Decoder sa volá len raz
- Decoder hodí na obraz N ($=100$) detekcií a postupne ich posúva po obraze na ich správne miesto

Reprezentácia detekcie


Detekcia v sebe zahŕňa informáciu:

- ohraničujúci obdĺžnik (box)
- dôveryhodnosť (confidence)
- kategóriu (class)

DeTR kóduje detekciu vektorom s dĺžkou dimenzie latentného priestoru. Ako? To necháme na sieť samotnú, nech si vymyslí takú reprezentáciu aká jej vyhovuje

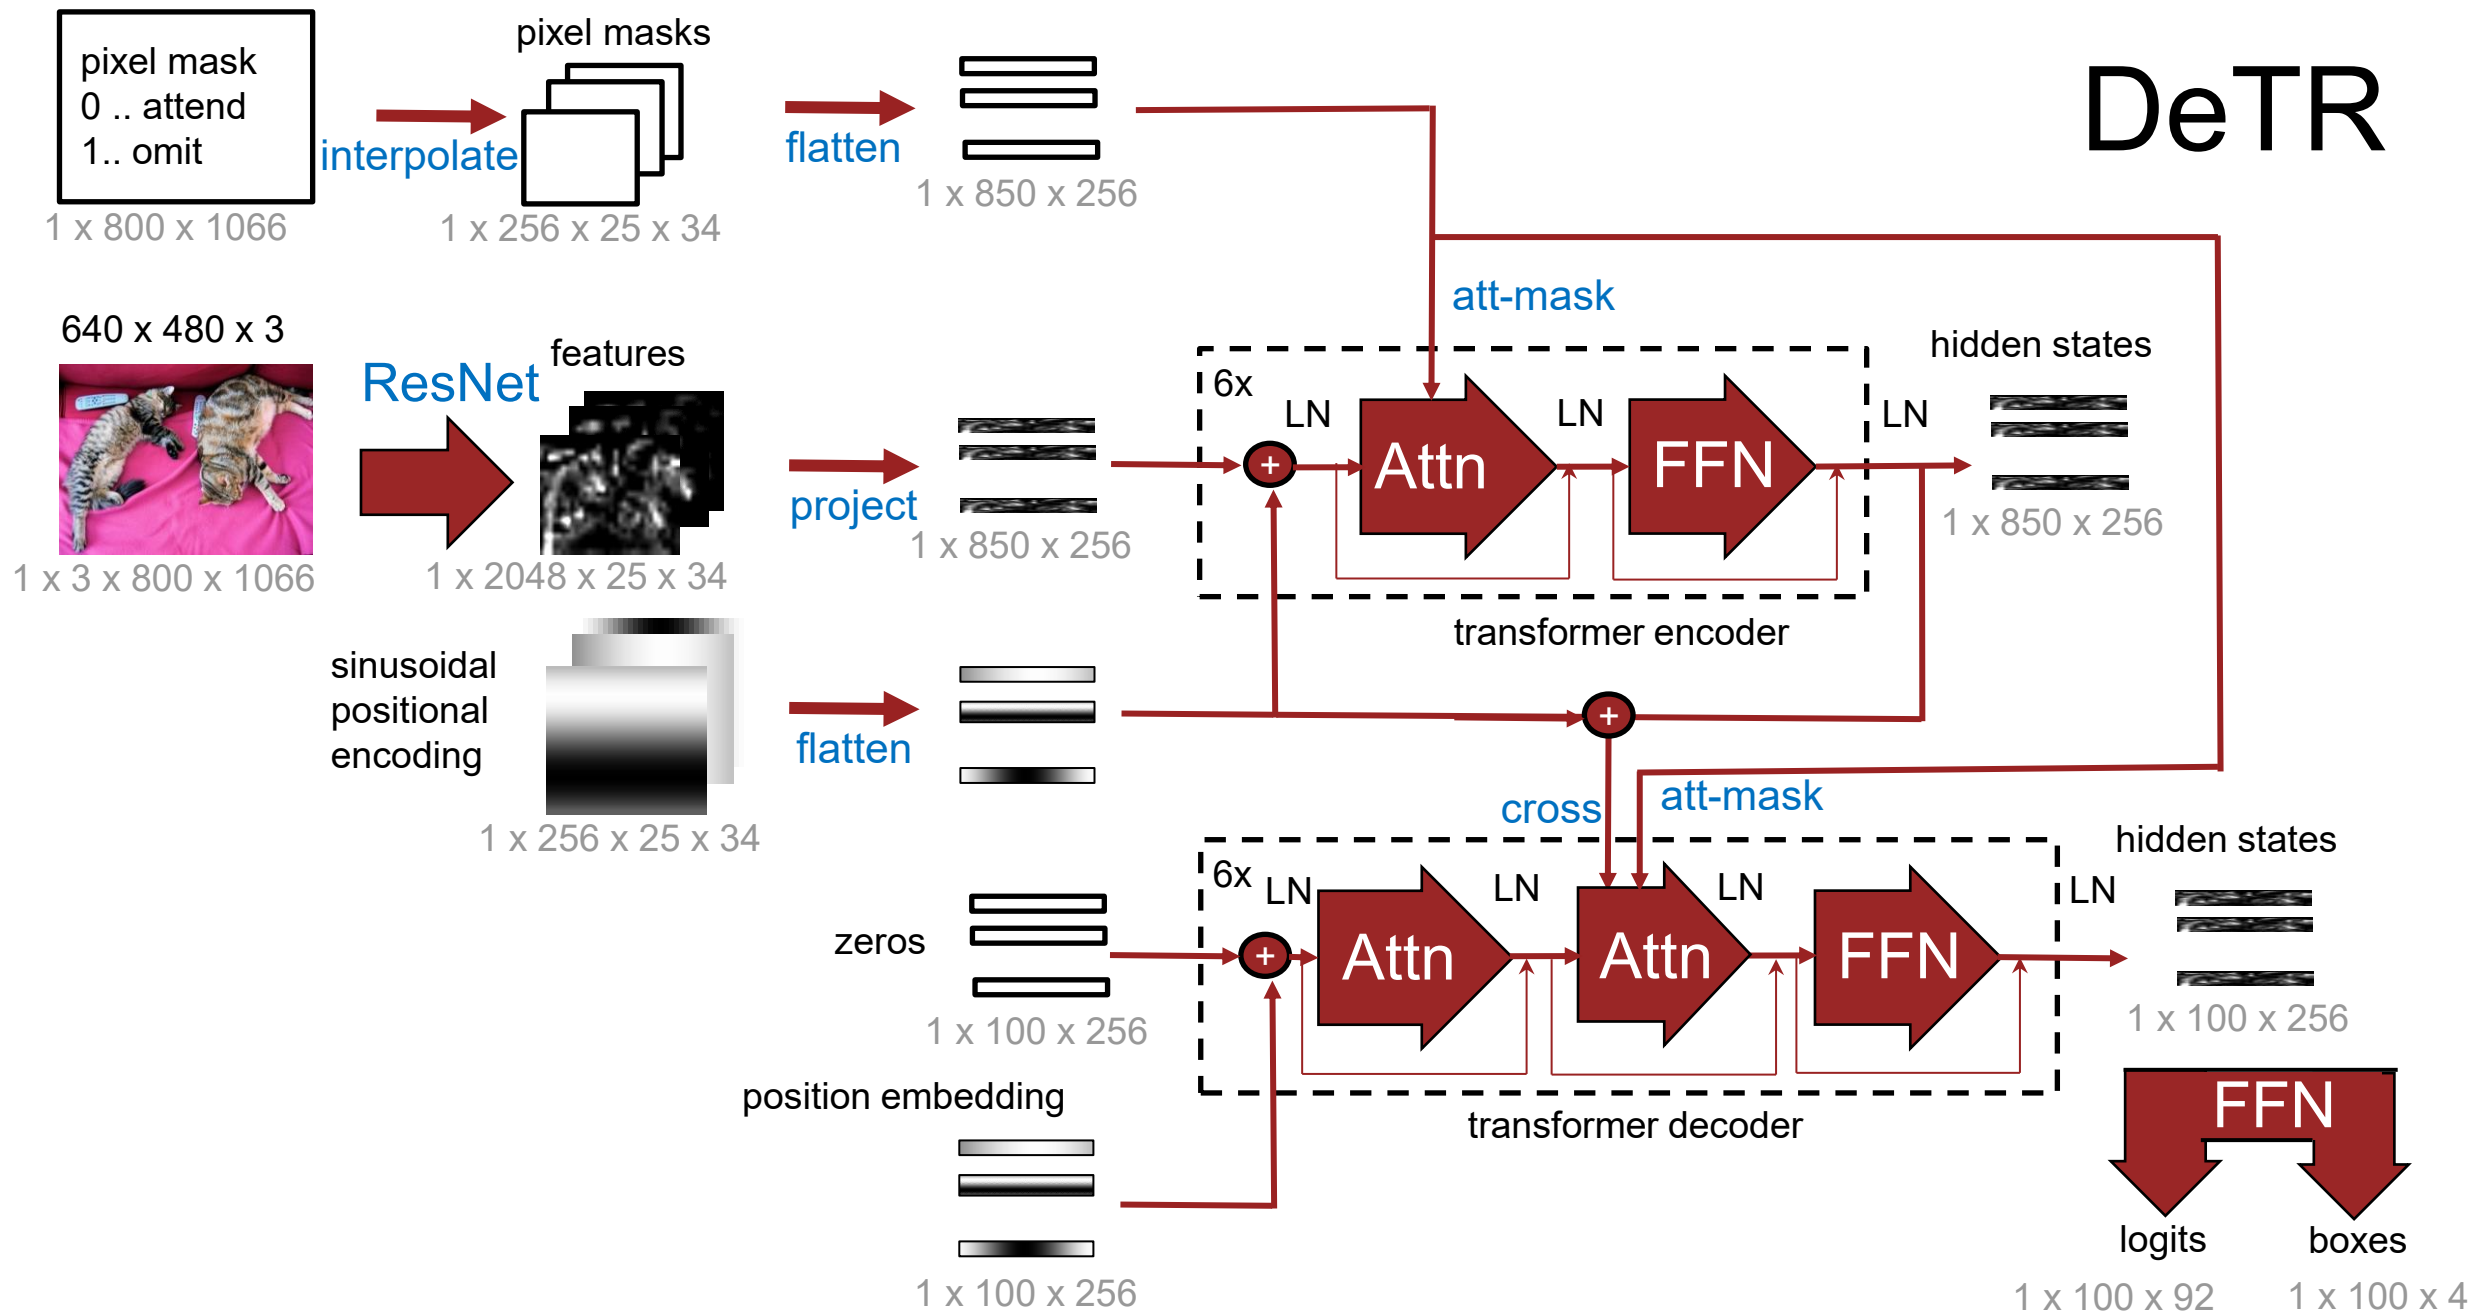
Masked Attention


DeTR umožňuje hľadať
objekty len na určitom
mieste obrázku, ktoré
definuje maskou



$$Att(Q, K, V) = \left[\text{softmax} \left(\frac{QK^T}{\sqrt{d}} \right) + \text{mask} \right] V$$


DeTR






Sinusoidal positional encoding




$$P(k, 2i) = \sin\left(\frac{k}{n^{2i/d}}\right)$$



$$P(k, 2i + 1) = \cos\left(\frac{k}{n^{2i/d}}\right)$$



Sonda (Probe)





0

couch


cat

remote

cat

remote

1



couch

cat

remote

cat

remote

2



couch


cat

remote

cat

remote

3



couch

cat

remote

cat

remote

4



couch


cat

remote

cat

remote

5



couch

cat

remote

cat

remote

6




Fundamentálne modely

- ViT i DeTR sa trénujú na určitú sadu kategórii objektov
- Mohli by sme urobiť modely, ktoré:
 - klasifikujú akýkoľvek obrázok
 - nachádzajú akékoľvek objekty
 - netreba trénovať, stačí ich použiť (zero-shot), alebo len málo doplniť (few shot)
- Prečo nie?
 - dát máme mnoho z čohokoľvek
 - ale nedokážeme ich anotovať, je ich nielen veľa, ale nevieme čo všetko znamená „akýkoľvek“

DINO


Distillation with
NO labels



DINO

Distillation with
NO labels


- trénujeme z veľkého množstva obrázkov destiláciou bez anotácií



- porovnáme čokoľvek
- vidíme kde sa nachádza čokoľvek

CLIP


Contrastive Language-Image Pre-training



- CLIP je špeciálne trénovaný vizuálny transformer + textový transformer (veľký jazykový model), oba encoder-only
- ich spriahnutie sa dosahuje trénovaním s kontrastívnou chybovou funkciou, pri ktorom žiadame, aby bol skalárny súčin kódov zodpovedajúcich si vzoriek väčší než kódov tých, čo nezodpovedajú


CLIP

Contrastive Language-
Image Pre-training



- Pri používaní potom porovnávame jeden aktuálny kód (zodpovedajúci položenej otázke alebo videnému obrazu) sady dopredu pripravených kódov (z textov alebo obrazov)
- Kde najväčší skalárny súčin, tak to je pár, ktorý si zodpovedá (musí tam taký byť)
- vidíme čokoľvek sa dá pomenovať
- vieme rozlišovať medzi slovne zadefinovanými kategóriami

GLEE



GLEE



The first dog from the right



- segmentuje “čokoľvek”, čo vieme opísať slovami, obodkovať alebo počmárať

SAM3 Model Architecture with Full LoRA Adaptation

